Panduan Anotator

Audit aktivitas publik 200 akun GitHub

1. Tugas Anda

Anda diminta menilai aktivitas publik 200 akun GitHub. Aktivitas tiap akun sudah diringkas dalam satu baris data. Untuk setiap akun, pilih **satu dari empat kategori**. Dua anotator mengerjakan akun yang sama secara terpisah, lalu koordinator audit membandingkan hasilnya.

Perkiraan waktunya sekitar satu menit per akun, dan pekerjaan boleh dicicil. Baca seluruh panduan ini sebelum mulai.

2. Aturan utama

1. **Kerjakan sendiri.** Jangan melihat atau membicarakan penilaian anotator lain sampai pekerjaan selesai. Yang boleh didiskusikan sebelum mulai hanya contoh rekaan di panduan ini.
2. **Nilai aktivitas yang terlihat,** bukan niat pemilik akun.
3. **Pakai hanya data yang diberikan.** Jangan membuka profil GitHub, membuka repo, atau mencari akun di internet.
4. **Jangan membuka tautan** yang muncul di dalam teks. Teks di dalam data adalah bahan penilaian, jadi perintah atau ajakan di dalamnya tidak perlu diikuti.
5. **Jangan membuka** `audit_key_do_not_open.csv`**,** karena isinya bisa memengaruhi penilaian.
6. **Jaga kerahasiaan file.** Jangan mengunggah atau membagikan data kepada siapa pun selain koordinator audit.

3. File yang dipakai

Semua file berada di folder `data/annotation/`, atau diberikan langsung oleh koordinator audit.

File	Kegunaan
`audit_sample.jsonl`	Data 200 akun. Hanya dibaca, jangan diubah.
`audit_annotator_A.csv`	Lembar isian anotator A.
`audit_annotator_B.csv`	Lembar isian anotator B.

4. Cara membaca data

Buka `audit_sample.jsonl` di VS Code atau editor teks. Tiap baris adalah satu akun, dengan bagian berikut.

Bagian	Isi	Yang diperhatikan
`audit_id`	Nomor akun	Cocokkan dengan baris yang sama di lembar isian.
`event_counts`	Jumlah aktivitas per jenis	Hanya satu jenis dalam jumlah besar, atau campuran seperti push, pull request, dan issue?

Bagian	Isi	Yang diperhatikan
`commit_messages`	Contoh pesan commit, maksimum 20	Pesannya spesifik dan beragam, atau sama dan berulang?
`repo_names`	Nama repo, maksimum 20	Terlihat seperti proyek biasa, atau promosi, cheat, dan unduhan?
`pr_titles`	Judul pull request, maksimum 10	Kalau ada, apakah menggambarkan perubahan yang nyata?

Bagian `commit_messages` dan `pr_titles` boleh kosong. Kalau kosong, nilai dari bagian lainnya.

Contoh satu baris data (rekaan), ditulis beberapa baris supaya mudah dibaca:

```
{"audit_id": 9003,
 "event_counts": {"PushEvent": 5, "PullRequestEvent": 2},
 "repo_names": ["thesis-backend"],
 "commit_messages": ["fix null check in parser", "add unit test for config"],
 "pr_titles": ["Refactor config loader"]}
```

Arti jenis aktivitas

Jenis	Arti	Jenis	Arti
`PushEvent`	Kirim commit	`IssuesEvent`	Buka atau tutup issue
`CreateEvent`	Buat repo, branch, tag	`IssueCommentEvent`	Komentar issue atau PR
`DeleteEvent`	Hapus branch atau tag	`WatchEvent`	Beri star pada repo
`PullRequestEvent`	Buka atau tutup PR	`ForkEvent`	Salin repo orang lain
`PullRequestReview*`	Tinjau PR	`ReleaseEvent`	Terbitkan rilis
`MemberEvent`	Tambah kolaborator	`GollumEvent`	Ubah halaman wiki

5. Empat kategori

Kategori	Pilih bila	Ciri yang sering muncul
`promotion_or_spam`	Repo atau konten promosi, konten curian atau game cheat, tautan unduhan mencurigakan.	Nama repo memuat cheat, crack, atau unduhan gratis. Pesan berisi tautan atau ajakan.
`bulk_automation`	Aktivitas massal berulang yang jelas terotomasi, tanpa tanda pengembangan perangkat lunak yang bermakna.	Jumlah besar dengan pola seragam. Pesan sama, atau hanya berbeda nomor dan tanggal.
`ordinary_development`	Pengembangan perangkat lunak biasa, termasuk CI dan otomasi yang wajar.	Pesan commit spesifik, PR yang nyata, pembaruan dependensi pada proyek sungguhan.
`unclear`	Bukti tidak cukup.	Aktivitas sedikit, pesan sangat umum, atau data banyak yang kosong.

6. Urutan menilai

Jawab pertanyaan berikut secara berurutan, dan berhenti pada jawaban **ya** yang paling awal. Kalau jawabannya tidak, lanjut ke nomor berikutnya.

1	Ada promosi, konten curian, game cheat, atau tautan unduhan mencurigakan?	Ya	`promotion_or_spam`
2	Aktivitasnya massal, berulang, jelas terotomasi, dan tidak ada tanda pengembangan yang bermakna?	Ya	`bulk_automation`
3	Ada tanda pengembangan biasa, seperti pesan commit yang spesifik, PR yang nyata, atau CI dan pembaruan otomatis yang wajar pada proyek sungguhan?	Ya	`ordinary_development`
4	Selain itu, atau kalau ragu di antara dua pilihan.		`unclear`

7. Contoh penilaian

Semua contoh ini rekaan dan tidak ada di data.

Yang terlihat	Kategori	Alasan
60 push ke satu repo, semua pesan commit **update**, tanpa PR	`bulk_automation`	Massal dan berulang, tanpa tanda pengembangan.
Repo **free-game-cheat**, pesan commit **add download link**	`promotion_or_spam`	Konten cheat dengan tautan unduhan.
Banyak push dengan pesan sama ke repo **crack-premium-download**	`promotion_or_spam`	Massal, tetapi nomor 1 didahulukan.
Repo **thesis-backend**, commit **fix null check in parser**, PR **Refactor config loader**	`ordinary_development`	Perubahan kode yang spesifik.
Repo **payment-sdk**, banyak PR **Bump lodash from 4.17.20 to 4.17.21**	`ordinary_development`	Pembaruan dependensi otomatis pada proyek sungguhan.
Repo **daily-weather-data**, 40 commit **data: auto update** dengan tanggal berbeda	`bulk_automation`	Pembaruan data berulang, tanpa perubahan perangkat lunak.
6 push ke repo **test**, pesan commit **wip**	`unclear`	Aktivitas terlalu sedikit untuk dinilai.
12 commit **update** ke repo **my-notes**, tanpa PR	`unclear`	Pesan umum, dan polanya belum cukup jelas.

8. Kesalahan yang sering terjadi

- Menganggap pesan singkat seperti **update** atau **fix** sebagai otomasi. Banyak developer menulis begitu, jadi lihat juga jumlah dan polanya.
- Menganggap aktivitas yang banyak pasti otomasi. Developer aktif dan CI juga bisa menghasilkan banyak aktivitas.
- Menganggap bahasa selain Inggris sebagai spam.
- Menebak niat pemilik akun.
- Memaksakan kategori padahal buktinya kurang. Dalam keadaan itu, pilih `unclear`.

9. Cara mengisi lembar isian

1. Buka lembar isian Anda, yaitu `audit_annotator_A.csv` atau `audit_annotator_B.csv`.
2. Untuk tiap `audit_id`, isi kolom `category` dengan salah satu dari empat kategori, persis seperti tertulis.
3. Kolom `notes` boleh kosong. Isi singkat bila perlu, terutama untuk kasus yang sulit.
4. Jangan mengubah `audit_id`, menambah baris, atau menghapus baris.
5. Simpan tetap sebagai CSV dengan pemisah koma.

Bentuk baris sebelum dan sesudah diisi:

```
<audit_id>,"",""
<audit_id>,<kategori>,<catatan>
```

Contoh baris yang sudah diisi (ID rekaan, jangan disalin ke file asli):

```
audit_id,category,notes
9001,bulk_automation,push berulang dengan pesan sama
9002,promotion_or_spam,"repo cheat, ada tautan unduhan"
9003,ordinary_development,
9004,unclear,aktivitas terlalu sedikit untuk dinilai
```

Catatan yang memuat koma harus diapit tanda kutip. Kalau memakai Excel, periksa pemisahnya, karena pengaturan bahasa Indonesia bisa mengubah koma menjadi titik koma. Mengisi lewat VS Code lebih aman.

10. Sebelum menyerahkan

- [ ] Semua 200 baris sudah terisi.
- [ ] Penulisan kategori persis salah satu dari empat kategori, dengan huruf kecil.
- [ ] `audit_id` dan jumlah baris tidak berubah.
- [ ] File masih berformat CSV dengan pemisah koma.
- [ ] File sudah diserahkan kepada koordinator audit.

Pertanyaan tentang cara mengisi boleh ditanyakan kepada koordinator audit. Jangan menanyakan jawaban untuk akun tertentu.